ROADMAP ДИПЛОМНОЙ РАБОТЫ

12 октября - 1 декабря 2026 года. Команда: 2 человека.

Тема: Разработка метода обнаружения утечек конфиденциальных данных в истории публичных Git-репозиториев на основе методов искусственного интеллекта.

Цель: Работающий локальный прототип: доступная Git-история - кандидаты - признаки и контекст - ML-классификация - отчёт. Проверить, уменьшает ли контекст число ложных срабатываний при сопоставимой полноте обнаружения.

Основа: Pathfinding.cloud - основа контролируемых AWS-сценариев, не датасет Git-утечек [1]. Для оценки использовать SecretBench [3], CredData и собственные истории с искусственными секретами. Источники - ref.md; корпус - repo.md; категории - examples_leaks.md; стек - req.md.

12 октября – 15 октября. Постановка исследования

Согласовать проблему, исследовательские вопросы и девять категорий секретов. Разобрать 10 источников, распределить роли. Зафиксировать только статический анализ: без использования найденных credentials и проверки доступа к чужим сервисам.

Результат: Постановка задачи, границы исследования, обзор источников и критерии оценки.

16 октября– 20 октября. Архитектура и сценарии

Описать конвейер и схему данных. Из каталога 60 репозиториев выбрать 12 источников для пилота. По Pathfinding.cloud подготовить три описания AWS-сценариев и адаптировать их к искусственным Git-примерам; определить правила разметки.

Результат: Архитектура, manifest корпуса, сценарии и инструкция разметки.

21 октября - 28 октября. Датасет v1

Собрать и разметить кандидатов; два участника размечают независимо, третий разрешает расхождения. Создать истории: добавление/удаление, начальный коммит, ветка/merge, переименование, повтор и многострочный ключ. Разделить данные по семействам репозиториев и дубликатов.

Результат: Датасет v1, train/validation/test и тестовые истории с известными ответами.

29 октября - 9 ноября. Коллектор Git-истории

Реализовать чтение объектов, достижимых из полученных веток и тегов. Обрабатывать уникальные версии файлов, сохраняя commit/path и диапазоны строк. Проверить удалённые из HEAD секреты. В отчётах маскировать значения и использовать HMAC-отпечатки.

Результат: Коллектор истории, автоматические тесты и отчёт JSON/CSV.

10 ноября - 17 ноября. Сканер без ML и baseline

Объединить regex, энтропию и контекстные правила. К 1 декабря получить работающий сканер без ML. Настроить Gitleaks и TruffleHog без сетевой верификации [7–8]. Измерить полноту извлечения кандидатов и сопоставить одинаковый охват истории.

Результат: Baseline, протокол сравнения и зафиксированный тестовый набор к 6 декабря.

18 ноября – 29 ноября. ML-модель

Обучить Logistic Regression и Random Forest на признаках кандидата и контекста. Для текстового контекста проверить TF-IDF. Преобразования обучать только на train; пороги выбирать на validation. Сравнить варианты с контекстом и без него.

Результат: Сохранённая модель, конвейер признаков и сканер с ML к 20 декабря.

30 ноября – 1 декабря. Эксперимент и документация

Оценить выбранный метод на отложенном test set. Измерить precision, recall, F1, ложные срабатывания и время работы. Отдельно показать категории секретов, находки только в истории и полноту извлечения. Подготовить демонстрацию и описание ограничений.

Результат: Таблицы фактических результатов, воспроизводимый запуск и черновик экспериментальной главы.

Что сдаём к декабрю

Обзор источников; архитектура и методика; размеченный датасет и manifest; Git-сканер; baseline; ML-модель; результаты эксперимента; README и демонстрационный сценарий.

Синтетические и независимые данные оценивать отдельно. Наличие строки в репозитории не доказывает действительность credentials; улучшение от ML подтверждается только экспериментом.